IPB University
Bogor Indonesia
Program Studi
Sarjana, Magister & Doktor
Statistika & Sains Data

DIKTISAINTEK BERDAMPAK

STA1381 – Pengantar Sains Data

Pertemuan-5

Hubungan Antar Peubah

Anang Kurnia
Cici Suhaeni
Septian Rahardiantoro

2026

Outline

- Eksplorasi hubungan antar peubah
- Ukuran hubungan antar peubah
- Eksplorasi hubungan di text analysis

Eksplorasi hubungan antar peubah

- Pada pertemuan sebelumnya, dipelajari terkait eksplorasi dan visualisasi data.
  - Dapat dilihat bagaimana bentuk sebaran, ukuran pemusatan, dan ukuran penyebaran membantu memahami karakteristik dasar suatu peubah.

- Namun, sebagian besar insight yang bermakna tidak muncul dari satu peubah saja. Insight yang lebih mendalam justru diperoleh ketika kita menganalisis bagaimana peubah-peubah saling berinteraksi.

Mengapa hal ini penting?

Pertama, dalam feature engineering.
Kita perlu mengetahui fitur mana yang saling berhubungan secara bermakna dan bagaimana kombinasi antarfitur dapat memberikan sinyal yang lebih kuat terhadap target. Dengan mengidentifikasi pola hubungan ini, kita dapat menentukan fitur mana yang paling relevan dan berpotensi meningkatkan performa model.

Kedua, dalam pemilihan model.
Memahami hubungan antar fitur membantu kita menentukan pendekatan yang tepat—apakah model linear sudah cukup, ataukah kita memerlukan model berbasis pohon (tree-based) yang lebih mampu menangkap hubungan non-linear. Korelasi yang kuat antar fitur juga bisa menyederhanakan proses pemodelan, atau sebaliknya, menimbulkan kompleksitas yang perlu ditangani dengan hati-hati.

Ketiga, dalam pemeriksaan kualitas data.
Analisis interaksi dapat membantu mendeteksi redundansi antarfitur, ketidakseimbangan data, atau hubungan tak terduga yang mungkin mengindikasikan masalah pada data. Selain itu, kita juga dapat mengidentifikasi pola pada subkelompok tertentu yang berpotensi memengaruhi aspek fairness atau bias dalam model.

Eksplorasi jenis hubungan antar peubah

- Menemukan dan memahami interaksi tersebut secara visual.
- Dengan memanfaatkan visualisasi data, kita dapat melihat pola, hubungan, serta anomali yang mungkin tidak langsung terlihat hanya dari angka atau statistik ringkas.

Jenis hubungan antar peubah:

1. Numeric vs Numeric
2. Numeric vs Categoric
3. Categoric vs Categoric
4. Multiple variables together

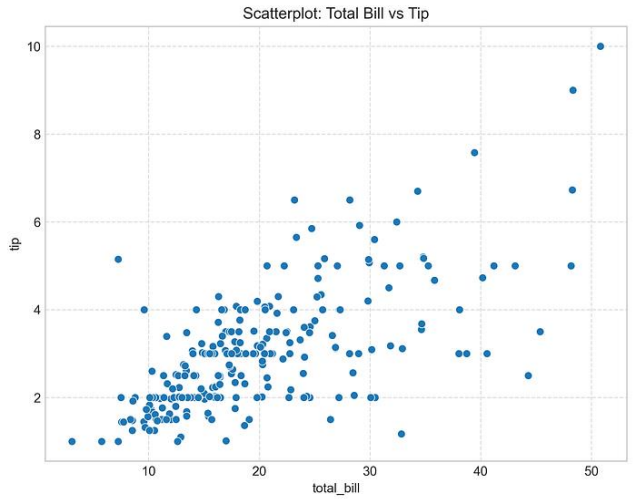
1. Numeric vs Numeric

- Ketika kedua fitur yang dianalisis sama-sama berupa numerik, kita ingin melihat pola tren, arah dan kekuatan korelasi, serta tingkat penyebarannya untuk memahami bagaimana keduanya saling berhubungan.

- Apakah hubungan tersebut linear—misalnya kenaikan satu fitur diikuti kenaikan fitur lain—atau justru non-linear dengan pola yang lebih kompleks?

- Visualisasi:
  - **scatter plot** membantu menampilkan sebaran titik data sehingga tren, klaster, dan outlier dapat terlihat dengan jelas,
  - **hexbin** dan **contour plot** sangat berguna untuk dataset berukuran besar karena mampu menunjukkan kepadatan dan pola distribusi secara lebih ringkas

Scatter plot

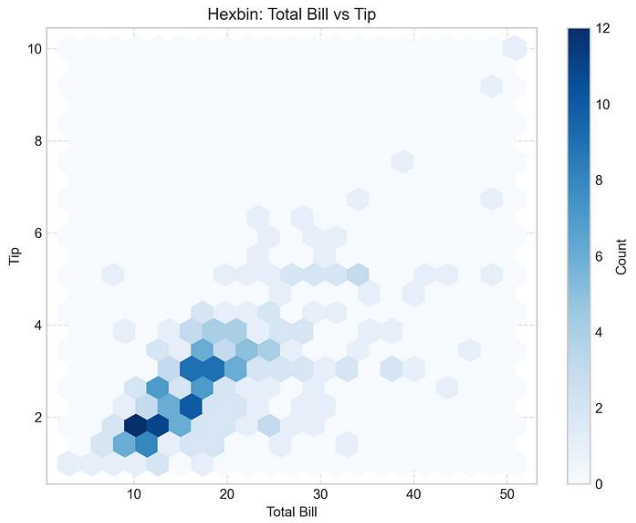


Output: Titik-titik yang miring ke atas.

Interpretasi: total_bill yang lebih tinggi → tip yang lebih tinggi (korelasi positif).

Mengapa ini penting: Cara paling sederhana untuk melihat hubungan sebelum melakukan pemodelan.

Hexbin



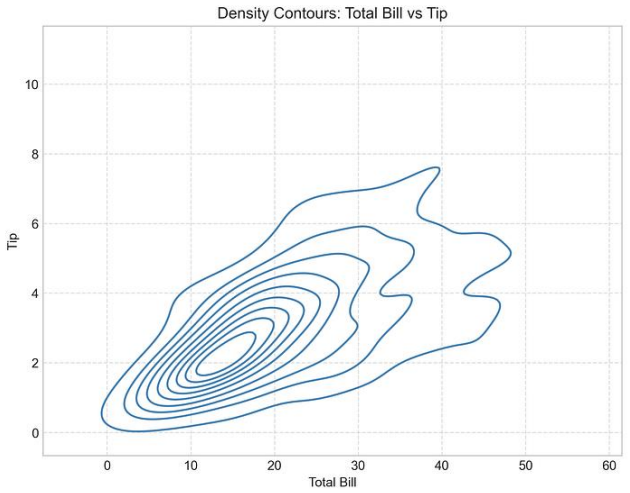
Scatterplot menjadi berantakan ketika titik-titik data saling bertumpuk. Hexbin mengelompokkannya ke dalam bentuk heksagon.

Output: Sel-sel heksagon yang diarsir lebih gelap pada area yang padat.

Interpretasi: Sebagian besar total_bill berada pada kisaran $10–20, dengan tip sekitar $2–3.

Mengapa ini penting: Memberikan kejelasan pada dataset yang padat — menunjukkan di mana sebagian besar data terkonsentrasi.

Contour Plot



Seperti peta topografi, kontur menunjukkan di mana data paling terkonsentrasi.

Output: Garis-garis kontur (seperti garis ketinggian).

Interpretasi: Tip meningkat seiring dengan naiknya total_bill, tetapi penyebarannya semakin lebar pada total_bill yang tinggi.

Mengapa ini penting: Membantu mengungkap bentuk distribusi lebih dalam, melampaui scatterplot sederhana.

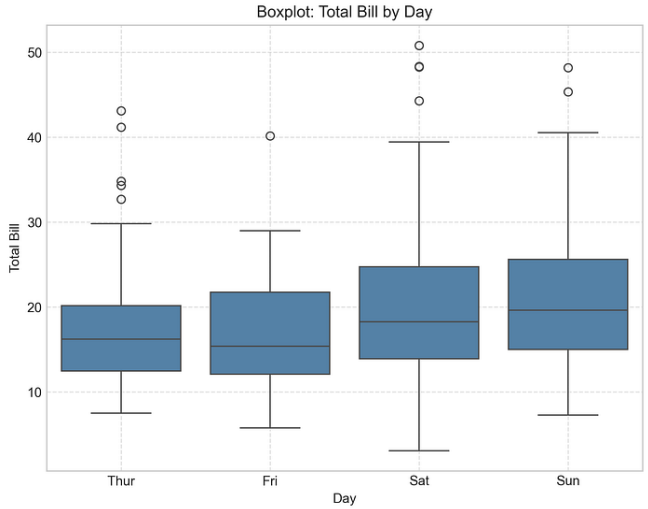
2. Numeric vs Categoric

- Ketika variabel numerik berinteraksi dengan kategori (misalnya, tagihan berdasarkan hari), kita perlu membandingkan distribusi antar kelompok.

- Visualisasi
  - **Boxplot**, **violin plot**, dan **strip plot** menampilkan median, variasi, serta pola kepadatan data.

- Hal ini membantu dalam rekayasa fitur (feature engineering) dan memudahkan untuk mengidentifikasi perbedaan antar kelompok.

Boxplot

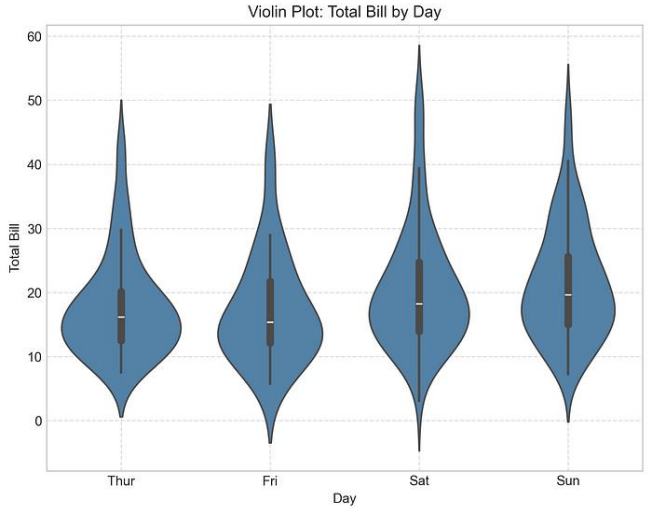


Boxplot merangkum bagaimana variabel numerik terdistribusi di berbagai kategori, dengan menampilkan median, sebaran, dan outlier.

Output: Kotak yang menunjukkan median, kuartil, dan outlier.

Interpretasi: Hari Sabtu memiliki variasi yang lebih tinggi dan terdapat outlier.

Violin Plot

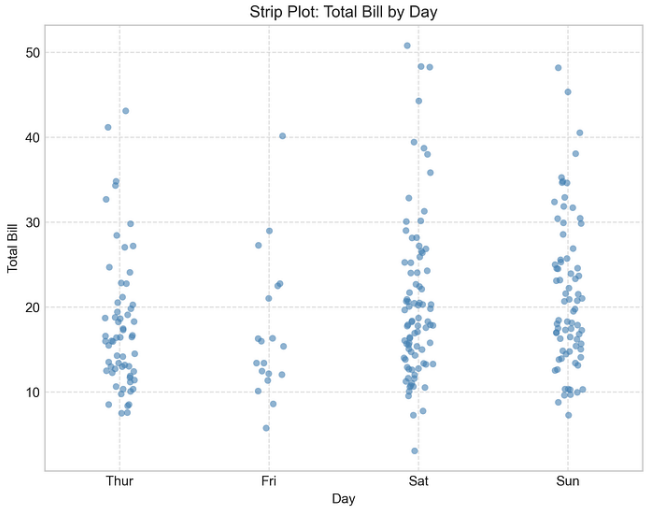


Violin plot menggabungkan boxplot dengan kurva density, sehingga menampilkan statistik ringkasan sekaligus bentuk sebaran.

Output: Bentuk “biola” simetris yang menunjukkan kepadatan data.

Interpretasi: Hari Minggu menunjukkan banyak tagihan pada kisaran menengah, sedangkan hari Sabtu memiliki ekor distribusi yang lebih berat.

Strip Plot



Strip plot menempatkan semua observasi di sepanjang kategori, sehingga memperlihatkan distribusi mentah dan tumpang tindih data.

Output: Semua titik ditampilkan dengan sedikit jitter (pergeseran acak kecil).

Interpretasi: Dapat dilihat nilai mentahnya; sebagian besar total_bill berkumpul di sekitar $20, tetapi ada outlier yang mencapai $50+.

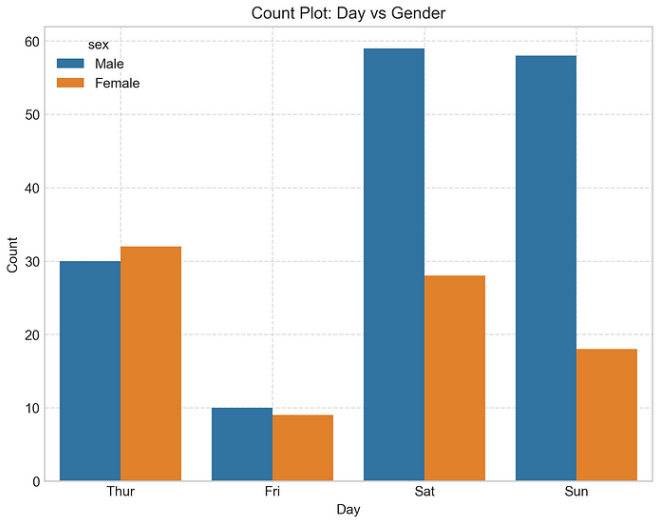
3. Categoric vs Categoric

- Ketika kedua peubah bersifat kategorik, tujuannya adalah untuk mengamati frekuensi, proporsi, dan ketergantungan.

- Visualisasi
  - **Mosaic plot** atau **Count Plot (Grouped Bar Chart)** membuat hubungan antar subkelompok menjadi terlihat.

- Hal ini membantu mendeteksi ketidakseimbangan, kemunculan bersamaan (co-occurrence), atau potensi efek interaksi.

Count Plot (Grouped Bar Chart)



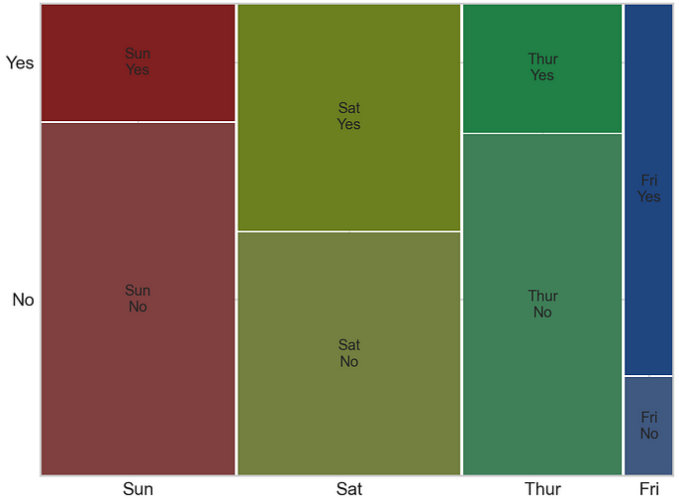
Count plot menampilkan frekuensi kategori dalam bentuk batang, sering kali dengan pemisahan berdasarkan subkelompok.

Output: Batang yang menunjukkan jumlah (frekuensi) tiap kategori, dapat dibedakan berdasarkan subkelompok.

Interpretasi: Dapat dilihat kategori mana yang paling sering muncul serta perbandingan antar subkelompoknya.

Mengapa ini penting: Memberikan gambaran yang jelas tentang sebaran frekuensi dan membantu mengidentifikasi ketidakseimbangan antar kategori.

Mosaic Plot



Mosaic plot memvisualisasikan bagaimana dua peubah kategorik saling berinteraksi dengan mengatur ukuran persegi panjang berdasarkan frekuensi.

Output: Persegi panjang yang ukurannya sesuai dengan frekuensi, dibagi menjadi perokok vs non-perokok dalam setiap hari.

Interpretasi: Non-perokok mendominasi di semua hari; akhir pekan secara keseluruhan lebih ramai.

Mengapa ini penting: Dengan cepat menunjukkan proporsi dan perbedaan subkelompok dalam data kategorikal.

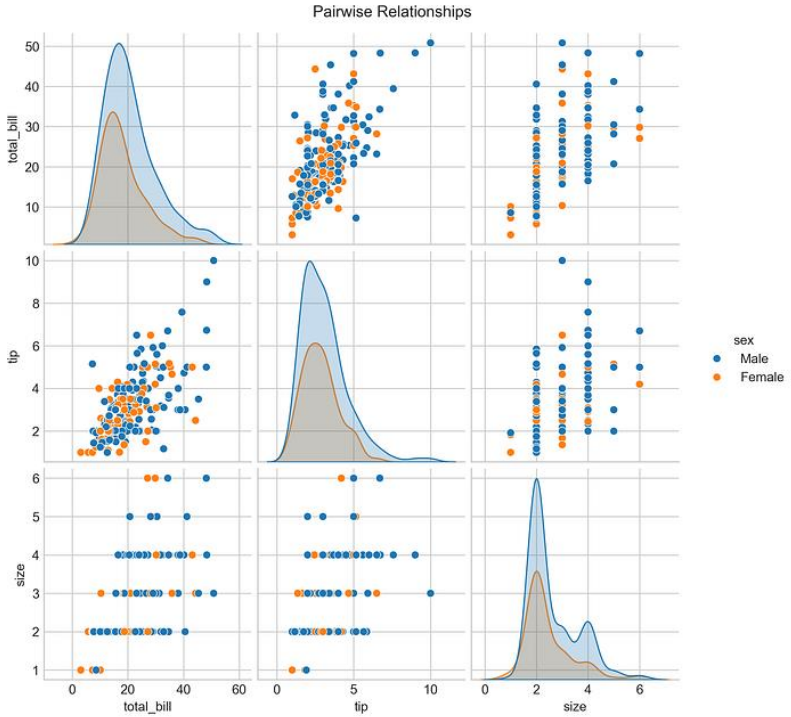
4. Multiple variables

- Data di dunia nyata sering melibatkan lebih dari dua peubah.

- Visualisasi
  - **Pairplot**, **facet plot**, **parallel coordinates**, dan **heatmap** memungkinkan untuk mengeksplorasi interaksi secara bersamaan.
  - Saat memiliki beberapa peubah numerik, scatterplot bisa menjadi terlalu ramai. Heatmap (matriks korelasi) adalah cara ringkas untuk menampilkan semua korelasi pasangan peubah sekaligus.

- Hal ini dapat mengungkap pola multivariat, tren subkelompok, dan korelasi yang mungkin terlewat jika hanya dilakukan analisis berpasangan.

Pairwise Plots (Scatterplot Matrix)



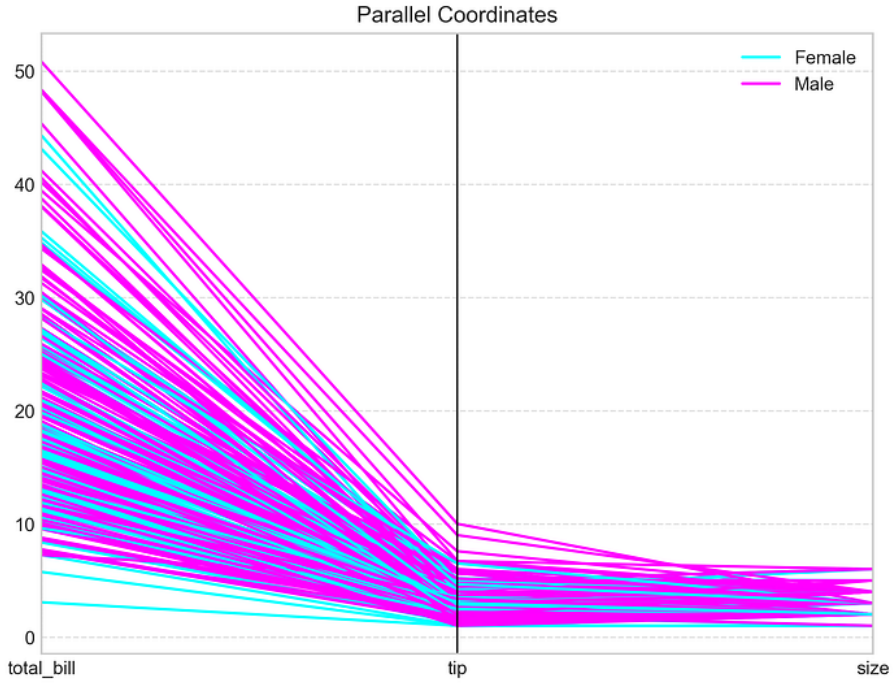
Pairplot menampilkan scatterplot dan histogram untuk semua pasangan peubah, memberikan pandangan menyeluruh tentang hubungan antarpeubah.

Output: Grid scatterplot + histogram.

Interpretasi: Tips meningkat seiring total_bill, ukuran kelompok menambah konteks, perbedaan gender terlihat.

Mengapa penting: Memberikan gambaran menyeluruh dalam satu tampilan untuk EDA (Exploratory Data Analysis).

Parallel Coordinates



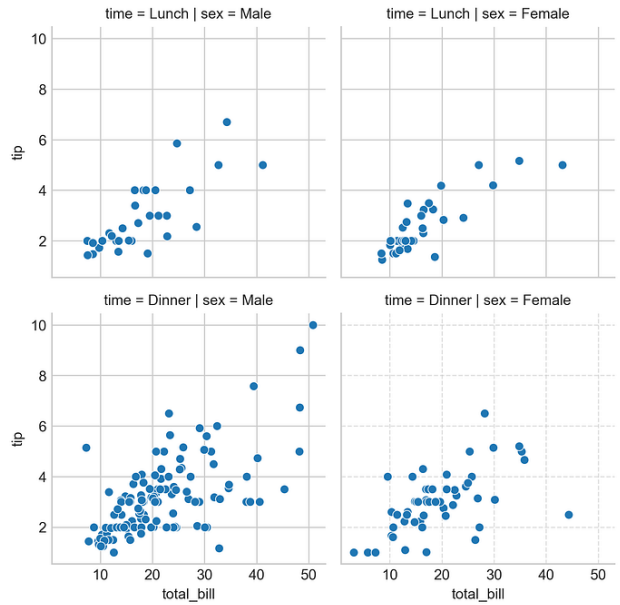
Parallel coordinates memetakan setiap observasi di beberapa sumbu untuk mengungkap pola multivariat.

Output: Garis-garis melintasi sumbu vertikal, dikelompokkan berdasarkan warna.

Interpretasi: total_bill yang lebih besar biasanya terkait dengan tip yang lebih besar, dipengaruhi oleh size.

Mengapa penting: Mengungkap tren multivariat yang tidak terlihat pada analisis pasangan variabel.

Facet Plots (Small Multiples)



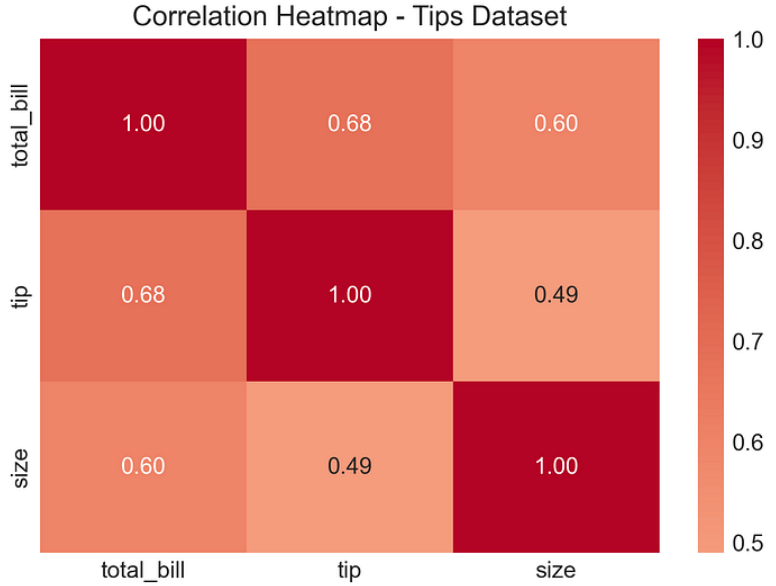
Faceting membagi data menjadi beberapa plot kecil berdasarkan variabel kategorikal, sehingga memudahkan perbandingan.

Output: Scatterplot terpisah untuk pria/wanita × makan siang/makan malam.

Interpretasi: Pria cenderung memberikan tip lebih banyak saat makan malam dibanding wanita.

Mengapa penting: Memecah kompleksitas menjadi bagian yang lebih mudah dicerna — memberikan wawasan untuk subkelompok.

Heatmap / Correlation Matrix



Output: Grid warna yang menunjukkan korelasi antara total_bill, tip, dan size.

Interpretasi: Tip meningkat seiring total_bill; size terkait dengan total_bill tetapi hubungan dengan tip lemah.

Mengapa penting: Menyoroti dengan cepat hubungan numerik terkuat untuk analisis lebih mendalam.

Ukuran hubungan antar peubah

Analisis Korelasi

Analisis korelasi mengukur derajat ketergantungan antara dua peubah.

- 2 Peubah kontinu: Koefisien korelasi Pearson
- Peubah kontinu vs Peubah biner: Point Biserial Correlation
- 2 Peubah biner: Koefisien Phi

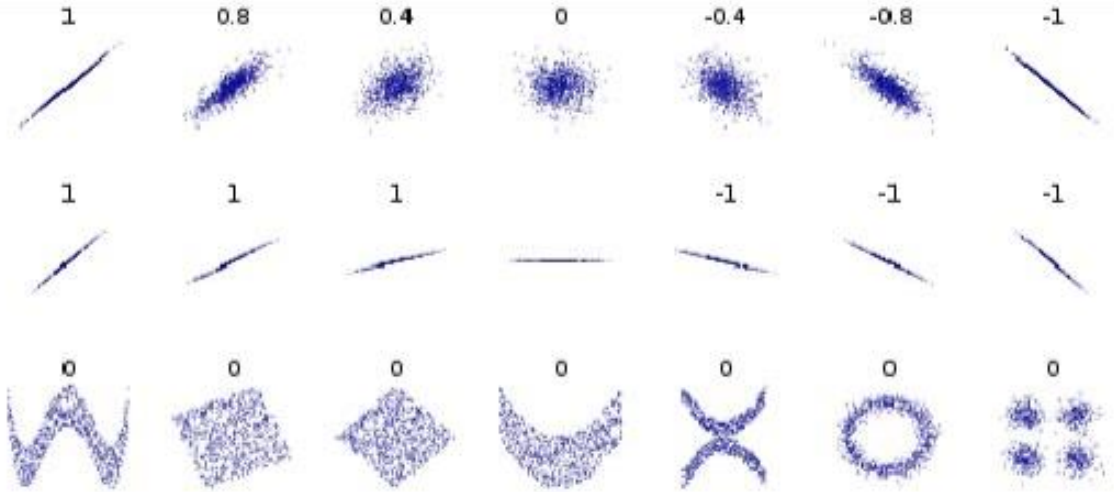
} Turunan dari korelasi pearson

- Peubah ordinal: rank-order correlation → Spearman rank-order correlation, Kendall tau

Korelasi Pearson

Mengukur keeratan hubungan linier 2 peubah numerik (kontinu)

$$r = \frac{cov(X,Y)}{s_X s_Y}$$



Rentang Nilai [-1, 1]

- 1: korelasi positif
- 0: peubah saling bebas
- -1: korelasi negatif

Point Biserial Correlation (r_{pb}) adalah korelasi momen produk Pearson antara satu peubah yang benar-benar dikotomis (biner) dan peubah kontinu lainnya. Secara aljabar, $r_{pb} = r$, sehingga r_{pb} dapat dihitung dengan cara yang sama seperti korelasi Pearson.

Koefisien Phi (ϕ) adalah korelasi Pearson ketika kedua peubah bersifat dikotomis (biner)

Ilustrasi:

Subject	Sex (male) X	Marks (Y)	Subject	Sex (Female (X)	Marks (Y)
1	0	46	11	1	58
2	0	74	12	1	69
3	0	58	13	1	76
4	0	67	14	1	78
5	0	62	15	1	65
6	0	71	16	1	69
7	0	54	17	1	59
8	0	63	18	1	53
9	0	53	19	1	73
10	1	67	20	1	81

X : peubah biner
Y : peubah numerik (kontinu)
→ Point Biserial Correlation (r_{pb})

$$r = \frac{Cov_{XY}}{S_X S_Y} = \frac{1.76}{0.497 \times 9.17} = 0.386$$

X: Gender — 0= Male, 1 = Female
Y: Ownership of Property — 0=No ownership, 1 = Ownership

X	1	0	1	1	0	0	0	0	1	1	1	0
Y	0	1	0	1	1	1	0	1	0	0	1	1

X : peubah biner
Y : peubah biner
→ Koefisien Phi (ϕ)

$$r_{XY} = \phi_{XY} = \frac{Cov_{XY}}{S_X S_Y} = \frac{-0.13}{0.52 \times 0.51} = -.465$$

Rank-Order Correlation

- Korelasi Pearson dihitung pada peubah numerik (kontinu).

- Korelasi Pearson tidak disarankan dalam dua kondisi:
  - pertama, ketika data berbentuk peringkat (rank), dan
  - kedua, ketika asumsi korelasi Pearson tidak dipenuhi oleh data (asumsi normalitas, tidak ada outlier, hubungan linier, peubah kontinu)

- Dalam kondisi ini, penerapan korelasi Pearson menjadi meragukan.

- Dalam situasi seperti itu, korelasi berdasarkan urutan peringkat (rank-order correlation) menjadi salah satu pilihan penting.

- Data pada skala ordinal disebut data urutan peringkat (rank-order data).

Spearman rank-order correlation

- Charles Spearman (1904) mengembangkan korelasi urutan peringkat yang disebut Spearman's rho (r_s) untuk mengukur hubungan antara dua peubah, terutama pada data urutan peringkat atau saat asumsi Pearson tidak terpenuhi.

- Nilai r_s berkisar dari –1 hingga +1, dengan tanda dan besarnya koefisien menunjukkan arah dan kekuatan hubungan monotonic antara peubah X dan Y.

- Nilai r_s tidak menunjukkan sebab-akibat, dan hubungan sempurna terjadi jika r_s = ±1, sedangkan r_s = 0 menunjukkan tidak ada hubungan.

$$r_s = 1 - \frac{6\sum D^2}{n(n^2-1)}$$

Where,

r_s = Spearman's rank-order correlation

D = difference between the pair of ranks of X and Y

n = the number of pairs of ranks

Jika ada peringkat yang sama, korelasi r_s dapat didekati dengan korelasi pearson

$$r = r_s = \frac{\sum XY - \frac{(\sum X)(\sum Y)}{n}}{\sqrt{\left[\sum X^2 - \frac{(\sum X)^2}{n}\right]\left[\sum Y^2 - \frac{(\sum Y)^2}{n}\right]}}$$

Where,

r_s = Spearman's *rho*

X = ranks of variable X

Y = rank on variable Y

n = number of pairs

Ilustrasi:

Untuk seluruh siswa diperingkatkan terkait nilai ujian S1 (X) dan nilai ujian masuk (Y)

Students	Rank in Undergraduate Examination (X)	Rank in entrance test (Y)	R_X	R_Y	$D = R_X - R_Y$	D^2
A	1	4	1	4	-3	9
B	5	6	5	6	-1	1
C	3	2	3	2	1	1
D	6	7	6	7	-1	1
E	9	10	9	10	-1	1
F	2	1	2	1	1	1
G	4	3	4	3	1	1
H	10	9	10	9	1	1
I	8	8	8	8	0	0
J	7	5	7	5	2	4
$n = 10$						$\sum D^2=20$

$$r_s = 1 - \frac{6\sum D^2}{n(n^2-1)} = 1 - \frac{6 \times 20}{10(10^2-1)} = 1 - \frac{180}{990} = 1 - 0.1818 = 0.818$$

Kendall tau

- Kendall's tau adalah ukuran korelasi lain yang berguna dan dapat menjadi alternatif dari Spearman's rho, dikembangkan oleh Kendall (1938) berdasarkan analisis dua kumpulan peringkat, X dan Y.

- Nilai tau (ô) berkisar dari –1 hingga +1, dengan tanda dan besarnya koefisien menunjukkan arah dan kekuatan hubungan; nilai mendekati ±1 menunjukkan hubungan lebih kuat.

- Perlu dicatat bahwa Kendall's Concordance Coefficient berbeda dengan Kendall's tau dan tidak boleh disamakan.

$$\tilde{\tau} = \frac{n_C - n_D}{\left[\frac{n(n-1)}{2}\right]}$$

Where,

$\tilde{\tau}$ = value of ô obtained on sample

n_C = number of concordant pairs

n_D = number of discordant pairs

n = number of subjects

Concordant: pasangan peringkat disebut concordant jika arah perbedaan peringkat pada peubah X dan peubah Y sama, artinya keduanya "sejalan" atau setuju.

Discordant: pasangan peringkat disebut discordant jika arah perbedaan peringkat pada peubah X dan peubah Y berbeda, artinya keduanya "tidak sejalan" atau tidak setuju.

Ilustrasi:

- Ambil sepasang peringkat untuk dua subjek, A (1,1) dan B (2,3) pada peubah X dan Y. Jika tanda atau arah dari $R_X - R_X$ untuk subjek A dan B sama dengan tanda atau arah dari $R_Y - R_Y$ untuk subjek A dan B, maka pasangan peringkat tersebut disebut concordant (sejalan atau setuju).
- Pada contoh pasangan A dan B, $R_X - R_X = (1 - 2 = -1)$ dan $R_Y - R_Y = (1 - 3 = -2)$. Tanda atau arah pasangan A dan B sejalan, sehingga disebut pasangan concordant.
- Pada contoh pasangan B dan C, $R_X - R_X = (2 - 3 = -1)$ dan $R_Y - R_Y = (3 - 2 = +1)$. Tanda atau arah pasangan B dan C tidak sejalan, sehingga disebut pasangan discordant.

Subject	R_X	R_Y
A	1	1
B	2	3
C	3	2
D	4	4

Subjects	A	B	C	D	∑C	∑D
Rank of X	1	2	3	4		
Rank of Y	1	3	2	4		
	1	C	C	C	3	0
		3	D	C	1	1
			2	C	1	0
				4	0	0
					∑∑C = 5	∑∑D = 1

$$\tilde{\tau} = \frac{n_C - n_D}{\left[\frac{n(n-1)}{2}\right]} = \frac{5-1}{\left[\frac{4(4-1)}{2}\right]} = \frac{4}{6} = 0.667$$

Eksplorasi hubungan di text analysis

- Relation Extraction (RE)
  - Bagian tahapan penting dalam pemrosesan bahasa alami (NLP) yang secara otomatis mendeteksi dan mengklasifikasikan hubungan antara entitas dalam teks.

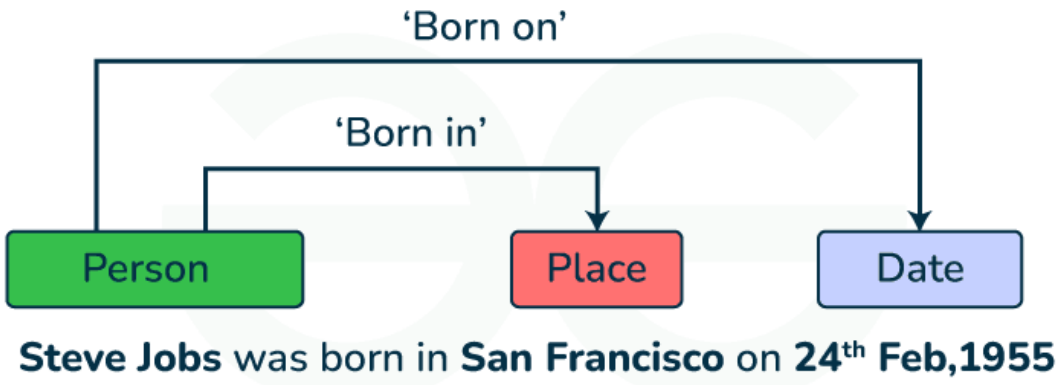
- Co-occurrence Analysis
  - Identifikasi kata-kata yang sering muncul berdekatan, biasanya digunakan untuk menentukan konteks dan kekuatan hubungan.

Relation Extraction dalam Natural Language Processing

- **Relation Extraction** adalah teknik yang membantu memahami hubungan antara entitas yang disebutkan dalam teks.

- Di dunia yang dipenuhi data teks tidak terstruktur, **Relation Extraction** menjadi teknik efektif untuk mengorganisir informasi, membangun grafik pengetahuan (knowledge graph), membantu pencarian informasi, dan mendukung proses pengambilan keputusan dengan mengidentifikasi serta mengklasifikasikan asosiasi antar entitas.

- Tujuan utama **Relation Extraction** adalah mengekstrak wawasan berharga dari teks yang memperkaya pemahaman kita tentang hubungan yang menghubungkan orang, organisasi, konsep, dan lain-lain.



Ilustrasi:

IPB University — Bogor Indonesia —

```
!pip install spacy-transformers
!python -m spacy download en_core_web_sm

import spacy
from transformers import pipeline

# Load spaCy's transformer-based model nlp = spacy.load("en_core_web_sm")

# Define a sample text for relationship extraction text = "GeekforGeeks was founded by Sandeep Jain. Sandeep Jain was a former teacher.
GeeksforGeeks is a computer science portal and offers various cources and articles."
# Process the text with spaCy
doc = nlp(text)
# Create a list to store extracted relationships
relationships = []

# Use Hugging Face's transformers NER pipeline for named entity recognition
nlp_ner = pipeline("ner", model="dbmdz/bert-large-cased-finetuned-conll03-english")
# Extract named entities and their labels
named_entities = nlp_ner(text)

# Iterate through the sentences in the document
for sent in doc.sents:
        # Iterate through the named entities (people, organizations etc.) in the sentence
        for ent in sent.ents:
                # Check if the entity has a known label and is a person or organization
                if ent.label_ in ["PERSON", "ORG"]:
                        # Extract the relationship
                        for token in sent:
                                if token.dep_ in ["attr", "nsubj", "dobj"]:
                                        relationships.append((ent.text, token.text))

for named_entities, relation in relationships:
        print(f"{named_entities} --> {relation}")
```

```
Sandeep Jain --> Jain
Sandeep Jain --> teacher
GeeksforGeeks --> GeeksforGeeks
GeeksforGeeks --> portal
GeeksforGeeks --> cources
```

Co-occurrence Analysis

- Co-occurrence Analysis mengidentifikasi kata atau entitas yang sering muncul berdekatan dalam teks.

- Digunakan untuk memahami konteks kata, mendeteksi hubungan antarentitas, dan mengukur kekuatan asosiasi, yang bisa diterapkan pada level kata, frasa, kalimat, atau dokumen.

- Umumnya menggunakan frekuensi bersama, matriks co-occurrence, atau skor asosiasi seperti Pointwise Mutual Information (PMI).

- Hasil dapat divisualisasikan dengan word clouds, network graphs, atau heatmaps untuk mempermudah interpretasi.

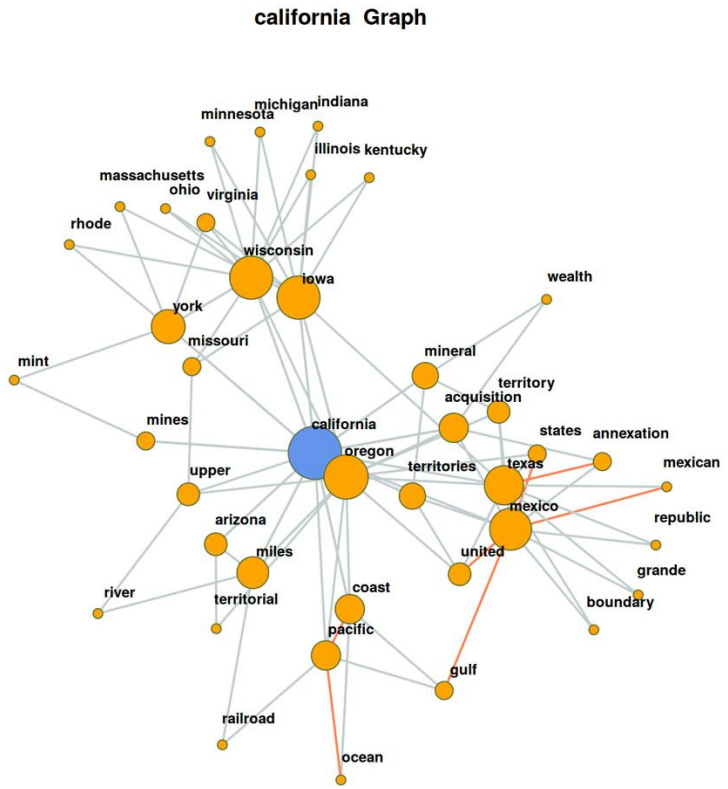
- Aplikasi:
  - Pembuatan knowledge graph
  - Analisis topik atau tren
  - Pencarian informasi kontekstual
  - Rekomendasi konten atau produk

- Keterbatasan:
  - Hanya menunjukkan keterkaitan, tidak menunjukkan sebab-akibat.
  - Bisa bias oleh kata umum (stopwords) jika tidak dibersihkan.

Ilustrasi output:

	advocating	affair	affairs	affect
advocating	11	0	0	0
affair	0	18	1	0
affairs	0	1	515	1
affect	0	0	1	99

Diinterpretasikan sebagai berikut: kata “affairs” muncul bersamaan 1 kali dengan kata “affect” dalam semua kalimat dataset. Kata “affairs” muncul sendiri sebanyak 515 kali.



Proses membangun network untuk istilah target dilakukan dalam dua langkah. Pertama, kita memperoleh semua istilah yang memiliki Co-occurrence signifikan dengan istilah target. Kedua, kita memperoleh semua Co-occurrence dari istilah-istilah yang diperoleh pada langkah pertama.

Sehingga secara umum tahapan Co-occurrence Analysis:

1. Deteksi text (kalimat, dokumen)
2. Perhitungan Co-occurrence
3. Signifikansi statistik: Agar tidak sekadar menghitung kemunculan bersama, kita harus menentukan signifikansinya.
4. Visualisasi

- Kemudian, terapkan deteksi hubungan antar peubah (fitur) data scraping yang sudah diperoleh masing-masing kelompok, interpretasikan!

Projek Kelompok – Sesi UTS

- Buatlah infografis yang berisi semua tahapan sains data pada kuliah yang meliputi:
  1. Data gathering: informasi detail data yang dikumpulkan melalui web scraping
  2. Data management: ekstraksi dan pembentukan fitur-fitur
  3. Data exploration & visualization: eksplorasi dan visualisasi fitur-fitur
  4. Variable relationship: ekstraksi hubungan antar fitur beserta eksplorasi & visualisasinya
  5. Variable selection: seleksi fitur yang tidak relevan digunakan dengan metode filtering
- Ukuran infografis: A3

- Penilaian:
  1. Kecepatan Pengiriman
  2. Orisinalitas
  3. Kesesuaian isi

- Pada Kuliah 7 → presentasi infografis setiap kelompok (5 menit) + diskusi dan tanya jawab (5 menit)

- Batas waktu pengumpulan infografis: **29 September 2026, pukul 23:59 WIB**

Referensi

- https://medium.com/@ramyakniranjan/exploring-relationships-between-variables-a-visual-story-abc60947bca5
- https://www.geeksforgeeks.org/nlp/relationship-extraction-in-nlp/
- https://nballier.github.io/tm4ss.github.io/Tutorial_5_Co-occurrence.html
- https://github.com/tm4ss/tm4ss.github.io/blob/master/Tutorial_5_Co-occurrence.Rmd

Terima Kasih

IPB University

Bogor Indonesia

Inspiring Innovation with Integrity

in Agriculture, Ocean and Biosciences for a Sustainable World