KUNCI TEMPUR UTS - STA1381 PENGANTAR SAINS DATA

Target: bukan menghafal paragraf; kenali **kata kunci soal -> konsep/metode**. Alur besar: Gathering -> Management -> Explore -> Relationship -> Selection.

K1 - PENDAHULUAN & RUANG LINGKUP

Definisi inti: Statistics & Data Science = modeling, summarizing, analyzing data + matematika & computing untuk membuat prediksi dan keputusan di bawah ketidakpastian.

Area	Makna cepat	Contoh
1. Data acquisition	mengumpulkan / memperoleh data	scraping / API produk
2. Data management & preparation	membersihkan, menyiapkan, menstrukturkan	pisah string menjadi kolom
3. Data exploration	mencari pola, tren, anomali	histogram harga
4. Modeling for inference & prediction	membangun model statistik/matematika/komputasi	regresi prediksi harga
5. Visualization & communication	menyajikan insight	grafik + kesimpulan
6. Contextualization analytics	menghubungkan hasil dengan konteks keputusan	hasil analisis -> strategi

Lifecycle: Data Extraction -> Scrubbing Data -> Data Exploration -> Model Building -> Data Interpretation

K2 - DATA GATHERING

Istilah	Pahami sebagai...	Contoh soal
Scraping	ambil **isi/data spesifik** dari web -> tabel/teks/dataset	ambil nama + harga + rating produk
Crawling	jelajah **banyak halaman** dan mengikuti URL	1 halaman -> ikuti 100 link produk
Parsing	urai HTML mentah -> struktur yang bisa dibaca software	... -> elemen
XPath	query untuk navigasi/memilih elemen, atribut, teks HTML/XML	//div[contains(@class,'product')]
API	jalur resmi komunikasi software: request -> response	request cuaca -> response JSON
robots.txt	instruksi website bagi crawler; pedoman etika	jangan crawl bagian yang dilarang

JEBakan utama: Crawler = **collect links**; Scraper = **extract content**. Ada API resmi? Materi menganjurkan gunakan API; scraping dipakai saat data tampil di halaman dan akses langsung tidak tersedia, tetap etis & bertanggung jawab. Etika: jangan membebani server, hormati privasi/hak cipta/ToS, hindari data personal/sensitif.

Google Sheets: IMPORTXML(url, xpath_query, locale) = URL + XPath + locale.

K3 - MANAJEMEN DATA & REGEX

Tujuan: raw string -> variabel terstruktur / siap analisis. Contoh: "93.142 km,Automatic,Tangerang Selatan," -> Jarak | Transmisi | Wilayah.

Regex	Arti	Contoh
()	grouping	(km|m)
|	OR / alternatif	(km|m|cm)
[a-z]	huruf kecil a-z	[a-z]+
[A-Z]	huruf besar A-Z	[A-Z][a-z]+
[0-9]	satu digit 0-9	"A7" cocok
[0-9]+	1+ digit berurutan	"12345" -> 12345
\w	word character	huruf/angka/_
\d	digit	cocok 0-9

stringr (R)	Ingat	Contoh
str_subset()	**PILIH** elemen cocok	c("A1","B") + [0-9] -> "A1"
str_detect()	**ADA?** -> TRUE/FALSE	"A1" + [0-9] -> TRUE
str_extract()	**AMBIL** pattern pertama	"abc123" + [0-9]+ -> "123"
str_extract_all()	**AMBIL SEMUA**	"A1 B22" + [0-9]+ -> 1,22
str_locate()	**POSISI** pattern	cari posisi digit
str_replace()	**GANTI** pertama	"Auto-Car" ganti "-" -> " "
str_replace_all()	**GANTI SEMUA**	hapus semua ","

K4 - EKSPLORASI & VISUALISASI

Kalau pertanyaannya...	Pakai...	Contoh
Distribusi 1 numerik	Histogram / Density / Boxplot	distribusi nilai ujian
Numerik menurut kategori	Boxplot / Violin / Strip	gaji menurut gender
Numerik x numerik	Scatterplot (+ trend line)	tinggi vs berat
Kategorik x kategorik	Count / Grouped Bar / Mosaic	merokok vs penyakit
Banyak variabel	Pairplot / Facet / Parallel / Heatmap	total_bill, tip, size
Waktu	Time series / stacked area/bar	penjualan bulanan
Geografis	Thematic map	harga per kabupaten

BEDAKAN: Histogram = frekuensi dalam bin; Density = bentuk distribusi halus; Boxplot = median + sebaran + outlier; Violin = boxplot + density; Scatterplot = hubungan 2 numerik. Pilih grafik berdasarkan **pertanyaan**, bukan hanya tipe data.

K5 - HUBUNGAN ANTAR PEUBAH

Langkah 1: lihat TIPE DATA. Jangan langsung lihat nama metode. Tanyakan: "dua variabel ini tipenya apa?"

TIPE 2 PEUBAH	PILIH	CONTOH
Numeric/Continuous + Numeric/Continuous	**PEARSON** hubungan linier	total_bill vs tip; tinggi vs berat
Continuous + Binary	**POINT BISERIAL** turunan Pearson	nilai ujian vs lulus Ya/Tidak
Binary + Binary	**PHI** Pearson untuk 2 biner	merokok Ya/Tidak vs penyakit Ya/Tidak
Ordinal / Rank	**SPEARMAN / KENDALL** rank-order; monotonic	ranking kepuasan vs ranking pelayanan

Cara baca nilai korelasi

Tanda	Makna	Contoh
+	arah positif: X naik -> Y cenderung naik	r = +0.80 -> positif kuat
-	arah negatif: X naik -> Y cenderung turun	r = -0.92 -> negatif sangat kuat
|r| mendekati 1	hubungan makin kuat	|-0.92| > |-0.30|
r = 0	dalam framing materi: peubah saling bebas	tidak ada hubungan menurut framing slide

JANGAN KETUKER: korelasi/association **tidak sama dengan causation**. Pearson terutama untuk 2 peubah numerik kontinu dan hubungan linier; materi menyebut Pearson tidak disarankan untuk data rank atau saat asumsi normalitas, tidak ada outlier, linier, dan kontinu tidak terpenuhi -> pertimbangkan rank-order correlation.

Visualisasi untuk mengeksplor hubungan

Numeric x Numeric	Scatterplot	lihat pola, arah, kekuatan, linear/non-linear
Numeric x Categoric	Boxplot / Violin / Strip	bandingkan distribusi antar kelompok
Categoric x Categoric	Count / Grouped Bar / Mosaic	frekuensi, proporsi, ketergantungan
Multiple variables	Pairplot / Facet / Heatmap / Parallel	pola multivariat / subkelompok

K6 - SELEKSI PEUBAH / FILTERING

Tujuan: menyisihkan prediktor yang tidak relevan -> mengurangi kompleksitas, membantu prediksi/stabilitas/interpretasi, dan mengurangi risiko overfitting. Materi juga menyoroti masalah p >> n.

Bagian A - bedakan 3 METODE SELEKSI

METODE	APA YANG DILAKUKAN?	CONTOH
FILTER	**Statistik dulu -> baru model.** Setiap fitur diberi skor/ranking berdasarkan hubungannya dengan target.	Chi-square, ANOVA, Pearson/Spearman, Information Gain, Mutual Information
WRAPPER	**Subset -> train -> evaluate -> ulangi.** Pilih subset berdasarkan performa model.	Forward Selection, Backward Elimination, RFE
EMBEDDED	**Seleksi terjadi saat training.** Seleksi sudah jadi bagian algoritma.	LASSO, Elastic Net, Decision Tree, Random Forest feature importance

HAFAL GAMPANG: FILTER = **statistik** | WRAPPER = **coba subset + nilai model** | EMBEDDED = **pilih sambil training**.

Bagian B - kalau FILTERING, pilih uji dari TIPE FITUR + TARGET

FEATURE	TARGET	METODE	CONTOH
Categorical	Categorical	**CHI-SQUARE**	Gender vs Status Pembelian
Continuous / Numeric	Categorical	**ANOVA F-TEST**	Age vs Class Pembelian
Continuous / Numeric	Continuous / Numeric	**CORRELATION**	Age vs Income

Bagian C - pahami arti tiap uji

Chi-square	H0: **tidak ada hubungan**; H1: ada hubungan signifikan. Bandingkan observed vs expected frequencies. **p kecil -> H0 ditolak.**	Pilih p-value terkecil / p < 0.05 / top-k.
ANOVA	Continuous feature + categorical target. p-value kecil -> perbedaan antar kelompok lebih meyakinkan.	Ranking fitur berdasarkan p-value.
Correlation	Feature & target numerik. Pearson r berada pada [-1,1].	Bisa ranking berdasarkan |r| atau p-value.

CONTOH INTEGRASI - soal UTS sering begini

Target = Status Pembelian (binary).
Gender (binary) -> **Phi** untuk ukuran hubungan, dan saat **filtering kategori x kategori** -> **Chi-square**.
Age (continuous) -> **Point Biserial** untuk ukuran hubungan dengan target binary, dan saat **filtering continuous x categorical** -> **ANOVA**.

POLA SOAL: "hubungan antar peubah?" -> pikir K5 (Pearson / Point Biserial / Phi / Spearman-Kendall). "pilih fitur sebelum model?" -> pikir K6 Filter. "jenis fitur-target?" -> Chi-square / ANOVA / Correlation.

URUTAN PROYEK UTS: Data Gathering -> Data Management -> Exploration & Visualization -> Variable Relationship -> Variable Selection.